

PSEUDO-CODIFICA BUILD_ARFF

Nella pseudocodifica **vengono omessi**:

- creazione di un file contenente l'elenco delle features
- inizializzazione e copia delle features in un dizionario ordinato
- normalizzazione delle features
- scrittura del file arff ed interrogazioni spotlight / sparql
- altri dettagli implementativi

build_arff

init_arff // genera il file arff con l'elenco degli attributi (features + classe)

for each *t* in *topics*

```
write_arff_from_xml(t) // 1. legge il file xml contenente i post della sezione
                        // 2. inizializza il post
                        // 3. estrae le uri da spotlight
                        // 4. richiede le relazioni dbo da sparql
                        // 5. calcola e normalizza le features
```

write_arff_from_xml(topic)

for each *element* in *topic*

```
text ← element.read_body
post ← new_post(text,topic) // inizializza il post
post.init_features          // genera l'elenco di features
write_to_arff(post)        // scrive la riga corrispondente al post nel file arff
```

(post).init_features

```
uris ← get_uris           // interroga spotlight per ottenere la lista di uri
rf ← get_r_features(uris) // dizionario delle feature ottenuto dalle relazioni
kf ← get_k_features(uris) // dizionario delle feature ottenuto dalle keywords
of ← get_o_features(uris) // altre features (numero di uri e lunghezza del testo)
normalize_features        // normalizza i valori delle feature in [0,1]
```

get_r_features(uris)

relationships_features ← *empty_dictionary*

for each *u* in *uris*

 relationships_count ← *empty_dictionary*
 relationships_count.put(anime_relationships_count)
 relationships_count.put(beer_relationships_count)
 relationships_count.put(fitness_relationships_count)

 relationships_features.add(relationships_count)

return relationships_features

get_k_features(uris, keywords)

keyword_features ← *empty_dictionary*

string_blob ← *empty_list*

for each *u* in *uris*

 string_blob.addAll(relevant_resources(*u*))

for each *k* in *keywords*

 count ← keywords_count(string_blob, *k*)
 key ← keyword.superGroup(*k*) // insieme a cui appartiene la parola chiave
 keyword_features.sum(key, count)

return keyword_features